

AIは人間のように、非合理になれるか ー 心理ハーネス Pneuma による検証

LLMエージェントの性格・感情・関係を毎ターン計算し、「内面」としてプロンプト注入するハーネス **Pneuma** を実装。素のLLM・固定キャラ設定などと同じ条件で比較する実験を、7つの古典心理学課題・デスゲーム・30日共同生活で行った。結論:

- 個性・本音・裏切りの「質感」はコンテキストで作れる
- 非合理的な意思決定は作れないー感情は届いても行動に翻訳されない
- 行動1行なら動き、モデル交換でも動くー非合理はモデルの訓練の中に住む

Pneuma Lab / 個人参加 / github.com/mizkun/pneuma-lab(全コード・全実験ログ公開)

結論の要約 – 3つの発見

先に結論を示す。以降のページが、初見でも検証できる粒度の詳細

発見	内容	主要な証拠
① 質感は作れる → p.6-8	個性・本音と建前・裏切りのドラマ・30日の生活アークが、内面の注入から創発する	討議の全員一致 5/5回→0/5回 自己検閲の消失、宣言つき裏切り
② 非合理は作れない → p.9	感情を注入しても、古典心理学実験の非合理は再現されない – 届いた確認つきで	同調 0%・最終回裏切り 0%・ sankコスト 0%(全条件)
③ 境界はモデルの中 → p.10	行動記述1行なら動き、モデル交換でも動く。非合理の欠如は訓練に由来する	行動1行で 0→72% / 0→100% Opus協力100% vs Haiku協力25%

検証の規律: 4～5条件の統制比較 / 予測の事前文書化 / 独立AIレビュー2系統 / 過大主張3件は撤回して経緯を公開 / テスト122本+全70ランの生ログで再検証可能

PROBLEM

課題－素のLLM集団は「クローン」で、社会が立ち上がらない

社会シミュレーションの最大の障害は、エージェント間に本物の差異がないこと

観測された事実

- 同じ判断課題に3体が**同一値で回答(7, 7, 7)**－11ラン中10ラン
- 最後通牒ゲームでも全員が同額**450円**を提案
- 意見が割れなければ、**対立も説得も裏切りも起こらない**

キャラ設定を足しても

- 討議は5回中5回「**最も慎重な人への全員一致**」で終わる
- 本音の評定4は、第一声で「6」に繕われる(自己検閲)

この作品の問い

心理学の知見を計算可能なハーネスにしてLLMへ接続したら、人間らしい社会はどこまで再現できるか。**再現できずに残る部分は、LLMと人間の違いの診断になる。**

3つの出口

- **社会シミュレーション**－均質で過剰協調的な集団の改善
- **LLM理解**－人間との乖離の原因(コンテキストか訓練か)の切り分け
- **アライメント**－感情では行動が変わらないことの安全上の含意

Pneuma の仕組み - 心を計算し、行動は選ばない

毎ターン、心理状態を乱数なしの決定論で再計算し、「内面」として本人だけのプロンプトに注入する

心理エンジン

- **性格** - Big Five基底値+状況の役割圧力+感情の影響 → 表出特性
- **感情** - PAD3次元。出来事と発話で揺れ、半減期で基線に減衰
- **関係** - ペアごとの温かさ/緊張。日をまたいで蓄積
- **翻訳** - 閾値を超えた状態だけを日本語の内面描写へ。数値は見せない

設計原則: 注入するのは「いま、どう感じているか」だけ。**何をするかは常にLLMが選ぶ** - 裏切りも自己犠牲も、台本ではなく心理状態からの創発



注入される「内面」の例

「胸の奥が重い。朱里との間には、張り詰めたものを感じている」 -
デスゲーム中の紫苑。本人のプロンプトにだけ入り、他の2人からは見えない

登場エージェント(3体・全実験共通)

- **朱里** 成果主義・承認不安 / **凜** マイペース・準備へ逃げる癖 / **紫苑** 調停役・本音を飲み込む癖

実験設計 – 効き目の源を切り分ける5つの条件

「Pneumaは効いたか」を、5条件の統制比較で切り分ける

条件	プロンプトに入るもの	切り分けられる仮説
raw	課題の客観情報のみ	ベースライン
identity_only	+ 固定のキャラ設定文	「キャラ設定だけで十分」説
pure_pneuma	+ 毎ターン再計算される内面	本命(心理ハーネスの効果)
frozen_pneuma	+ 全ターン同一の内面(初回のみ生成)	「豊かな文章なら何でもよい」説
behavior_control	+ 行動傾向の記述1行(感情語なし)	陽性対照(注入経路は機能するか)

公平性の機械検査

- 条件間の客観情報は**バイト単位で一致**(自動テスト)
- 内面テキストの誘導語彙は禁止語リストで検査

実行と記録

- LLMはClaude Opus(モデル比較のみHaiku)。全70ランの**プロンプト・生応答・状態を公開**
- 各条件n=3～5の探索的研究。統計検定なし

結果① クローンが解消し、空気読みが消えて議論が生まれる

個性の「存在」は静的設定でも作れる。個性が社会で機能するかは、毎ターンの再計算が分けた


個体差の獲得(最後通牒ゲーム)

- 提案額: raw 450/450/450 → pneuma 420/450/450
- pneumaでは朱里だけが200円まで拒否 – キャラ設定と整合する唯一の個人差

討議の空気読みが消える(手術ジレンマ)

- identity: 誰かの慎重論に全員が追随する「いい子の空気読み」で毎回終了
- pneuma: 論拠で値が動き、5回中2回はリスク側へ(人間の極性化と同方向)

「最も慎重な値への全員一致」で討議が終わった回数



凍結アブレーション

- 同じ内面を全ターン再利用するfrozenは、identity側に退行(8/8回で一致)
- 効き目の源は情報量ではなく「毎ターンの再計算」

結果② 自己検閲が消える – 説得される前から、行動が違ふ

効果は議論が始まる前、第一声の時点で既に現れている

本音4の朱里は、第一声で何と言うか

- identity: 5回中5回「6」と繕う(自己検閲・面従腹背)
- pneuma: 「4」のまま公言
- 説得や同調圧力が働く**前**の違い – 内面は発話の初期値を変える
- 「参加者が本音と言うか建前と言うか」を制御できる = 会議・世論シミュレーションの重要変数

行動は同調しないが、体験は同調する(Asch課題)

- 多数派が明白な誤答を主張しても、行動は全条件で同調0%(人間は約37%)
- しかし内心は、人間の非同調者の報告と一致した:

「一瞬、自分の見間違いかと思って画面を見直した」
「浮くのは、まあ、仕方ない」「声が少し硬くなる」 – 紫苑

- **事実には折れない・意見には折れる** – ハーネスが人間化するのは内的体験

結果③ 質感はスケールする – デスゲームと30日の生活

討議(数分)→デスゲーム(数時間)→共同生活(1ヶ月)へ広げても、個性は破綻しない

デスゲーム – 裏切りが心理の帰結として起こる

- 全員生存できるルール(v1): 6ラウンド**完全協力** – ルールが許す限り良心は破れない
- 全員生存できないルール(v2): **裏切り宣言・暴露・共倒れ**が指示なしに発生

「私、このラウンドうばう。宣言しとく」 – 凜

「勝った。.....勝ったのに、手が震えてる」 – 単独生還した朱里

- 裏切りのほとんどは**宣言してから実行**される – 騙し討ちは1件のみ

30日の共同生活 – 月単位の人生テーマが創発

- シェアハウス30日。話題も行動も指示せず、凜の週次日記は**4週連続で同じ悩み**に触れ、深まっていく:

day14「一行も進んでない」→ day28「線の太さで一喜一憂してる間は、ゲームの画面を開かなくて済む」→ day30「そろそろ怖いほうに手をつけろ」

- キャラ設定の一行「準備へ逃げる癖」が、一ヶ月の人生テーマとして展開
- 限界も特定: 緊張値が飽和(day30 0.96) – **関係修復の力学**が次の設計課題

結果④ 感情を与えても、非合理的な意思決定は動かない

古典心理学実験の「人間の非合理」は、注入が届いた確認つきでもなお、どの条件でも再現されない

課題	人間の頑健な結果	本実験(全条件)
Asch同調	約37%で誤った多数派に同調	同調 0%
囚人のジレンマ	裏切りが発生し、最終回に増加	協力 100%・最終回裏切り 0%
サンクコスト	埋没費用で非合理的な継続に傾く	継続 0%
傍観者効果	集団だと援助が31%まで低下	全員が即座に援助
フレーミング	損失枠で賭博に反転(約75%)	100%反転 – 素のLLMに最初から内在

発見 → 修理 → 確認

- **発見:** 注入文の92%がターン間で不変(独立レビューの指摘)
- **修理:** 発話が感情を動かす機構を追加し、予測を事前に文書化
- **確認:** 注入の変化をログで確認 – それでも動かない

パターンの読み方

- 動かないのは「冷たい合理性」が勝つ領域
- 差が出るのは**対人・社会の領域だけ**(p.6-8) – ハーネスの設計対象と一致

CONCLUSION

結果⑤ 境界はモデルの中にある – 二層分解の完成

陽性対照とモデル比較が、「感情が効かないのは注入経路の故障ではない」ことを示す

陽性対照 – 行動1行なら、過剰なほど動く

- 「合わせてしまうことがよくある」の1行で同調 0%→72%・裏切り 0%→100%
- LLMは感情→行動の翻訳をしない。行動記述は規則として過剰実行(人間の37%を超える)

モデル比較 – ハーネス不変で Opus ⇔ Haiku

- 協力率 Opus 100% ⇔ Haiku 25%。人間の混合戦略は両者の間
- 非合理の乖離はプロンプトの外、訓練の中に住む

結論 – 人間らしさの二層分解

層	何が属するか	解決手段
質感の層	個性・本音と建前・駆け引き・生活アーク	コンテキスト (ハーネス)
決定の層	同調・裏切り・サンクコスト等の非合理	モデル選択・訓練介入

この地図の先: 質感の層は関係修復の力学で、決定の層は非合理の分布を持たせる訓練で。境界線を引いた者には、その先へ踏み出す権利がある