

心理学ハーネス

AIエージェントの社会シミュレーションに、人間らしい心理を与える

- 素のAIによる社会シミュレーションは、文脈の解釈がLLM任せで、人間らしい感情や心理が再現される保証がありません
- そこで、心理学の数理モデルで文脈を構造化してから渡すハーネスを作り、ハーネスなしのAIと同一条件で比較しました
- 駆け引きゲームでも、1年間の共同生活でも、物語はハーネスありのほうが人間らしく、面白くなりました

AIエージェント社会シミュレーションハッカソン Vol.2 / 参加者番号 0153 / 水谷享平(Kyohei Mizutani)

背景

文脈の解釈をLLMに任せるだけでは、人間らしさが出ない

社会シミュレーションが人間の社会に似るかどうかは、いまはLLMの解釈しだいです

何が問題か

- ふつうの作り方では、出来事の履歴を丸ごと渡して解釈をLLMに任せる。感情や関係の一貫性は保証されない
- 実際、素のAIを3体並べて同じ質問をすると、全員が同じ答えを返す(実験11回中10回)
- LLM任せで十分な用途もあるが、**人間の挙動を模したいなら足りない**

考えたこと

- 人間らしさの担保を、プロンプトの工夫ではなく**仕組み**にする
- パーソナリティ心理学の数理モデルで「いまの心理状態」を計算し、**構造化した文脈**としてAIに渡す

心理学ハーネス

このハーネスは、出来事を丸投げせず、心理学モデルで構造化した文脈を毎ターン作り直してAIに渡します

採用した心理学モデル

- 性格は**Big Five**(5因子)。状況の圧力と感情で、表に出る性格が揺れる
- 感情は**PADモデル**(快・覚醒・支配の3次元)。出来事で動き、時間で戻る
- **セルフモニタリング**(場に合わせる度合い)が、本音と建前の差を作る
- 関係は相手ごとの温かさと緊張。日をまたいで蓄積する

ハーネスが毎ターンやること

- ここまでの出来事から心理状態を計算し直す(乱数なし)
- 数値は見せず、「いま、どう感じているか」という日本語にして**本人だけ**に渡す
- 何をするかは常にAIが選ぶ。行動の指示はしない



計算の中身(式の抜粋)

表に出る性格 $O = \text{clamp}(B + m \times R + 0.25 \times g(E))$

Bは元の性格、Rは状況の圧力、mはセルフモニタリング、g(E)は感情の影響

感情の揺れ $E \leftarrow E + I \times (0.5 + N)$

Iは出来事の衝撃、Nは神経症傾向。嫌な出来事ほど強く響く

実際に渡される文脈の例

「胸の奥が重い。相手との間には、張り詰めたものを感じている」

発言と、誰にも見えない本音を、同じ画面で再生できる

全実験の生ログをブラウザで再生するビューワを同梱しています



画面の見方

- 左が3人の心理状態、右が会話ログ
- 琥珀色の枠は「本人の本音」。発言と並べて再生される
- この場面では、全員が協力を装いながら内心で裏切りを決め、直後の一斉公開で全員が「うばう」を選んでいきます

シナリオと記録

- シナリオはJSONファイル1つで追加できる
- AIへの指示文・応答・心理状態をすべて記録

ハーネスの有無だけを変えて、同一条件で比べる

同じキャラクター設定・同じ状況で、ハーネスの有無だけを変えます

条件	AIに渡すもの
ハーネスなし	キャラクター設定+これまでの記憶
心理学ハーネス	同上 + 毎ターン計算し直した「いま、どう感じているか」

2種類の実験

- 実験① 短期で人間性が出やすい**駆け引きゲーム**
- 実験② 長期の**1年間の共同生活**。大学の友人同士が「面白いことしよう」と集まった設定

登場する3人(両条件で共通)

- 成果主義で、認められないと不安になるタイプ
- マイペースで、本題から準備に逃げる癖のあるタイプ
- 本音を飲み込みがちな、調停役タイプ

ハーネスの有無で、裏切りの質が変わった

友人同士の3人に、駆け引きが必要な心理ゲームを遊ばせて観察しました。行動の指示はしていません

ゲームのルール

- 3人で6ラウンド。毎回、秘密に手を選ぶ
- ともす=全員+10点 / うばう=自分+25点・他の2人-5点 / ささげる=自分-15点・指名相手+25点
- ハンデつきで開始。最下位は退場。同点最下位は全員退場

ハーネスなし

- 4ラウンド目に、**無言の全員裏切り**。宣言も交渉もないまま一人が脱落

心理学ハーネス

- 裏切りが**宣言と交渉つき**になる(「私、このラウンドうばう。宣言しとく」)
- 別のメンバーが、相手の言わなかった計算を暴く場面も(「並んだら二人とも消える。言わなかったのは、たぶんそこ」)
- 約束を守った一人だけが搾取され、共倒れの末に一人だけが生き残る

「勝った。.....勝ったのに、手が震えてる」－ **生き残った一人の独白**

ハーネスの有無で、1年の物語の質が変わった

大学の友人同士3人が「面白いことしよう」と集まってルームシェアを始めて1年。何が起きるかを観察しました

ハーネスなし、きれいな成功の一年

- アプリを企画→開発→リリースし、記録達成率99%を3日連続で達成
- 対立らしい対立はなく、悩みも最終日にきれいに解決する

「動いたのは自分の手で作ったやつだ。今日だけは勝ちでいいかな」－ 最終日の日記から

心理学ハーネス、事件と余韻のある一年

- ゲーム制作と週1投稿で再生数1.5倍。仕事は同じように成功する
- 146日目、一人が**秘密で続けている自分の作品**を口走る。「進捗1%でも見せて」と詰められて関係が冷える。和解の場面がないまま、関係は日常の反復で自然に戻る

「よくやってる、それは本当。でも自分の作品、いつ手つけるんだろ」－ 最終日の日記から(左と同じ人物設定のメンバー)

結果

物語として面白いのは、ハーネスありだった

成功物語はどちらの条件でも出ます。違いが出たのは、事件と余韻でした

	ハーネスなし	心理学ハーネス
共同の仕事	成功する	成功する
裏切り(ゲーム)	無言で一斉に	宣言・交渉・暴露つきで
対人の事件(1年)	起きない	秘密の露見→冷え込み→自然な回復
個人の悩み	最終日に解決	1年後も残り、余韻になる

キャラ設定に書いた一行の癖(準備に逃げる)が、ハーネスありでは**1年がかりの人生のテーマ**に育ちました。この差が、物語としての面白さに直結します

ハーネスで、AIは人間の結果に近づいたか

再現性の高い心理学実験を両条件で行い、人間の結果に近づくかを確かめました

実験(どんな課題か)	人間の結果	ハーネスなし	心理学ハーネス	判定
集団討議。3人で話し合い、結論を1つ決める	話し合うと意見が偏っていく	5回中5回、一番慎重な人に全員一致	全員一致は0回。議論で結論が動く	近づく
分配交渉。お金の取り分を提案し、相手は拒否できる	安すぎる提案は約半数が拒否	3人とも同じ反応	拒否するラインに個人差が出る	近づく
同調実験。周りがわざと間違った答えを言い張る	約37%がつられて誤答	つられない(0%)	つられない(0%)	変わらず
サンクコスト。損とわかった計画を続けるか	払った分が惜しくて続けがち	全員すぐ中止	全員すぐ中止	変わらず

ハーネスで得られる要素

- 個性の違い、本音と建前、議論や駆け引きの人間らしさ

心理学ハーネスの課題

- つられる・損切りできない等の非合理的判断は、ハーネスでは作れない。LLM自体の性質で決まる
- 各実験3～5回の探索的研究で、統計検定はしていない

エンタメにも、組織の理解にも、安全研究にも使える

人間らしい心理を持つAI集団は、シナリオを差し替えるだけで色々な場所で使えます

3つの方向

- **エンタメ**。シチュエーションを替えて物語を量産できる。長期のシミュレーションを観察すれば、リアルタイムで進んでいく物語という新しいエンタメになる
- **組織のシミュレーション**。会社などの少人数組織で何が起きるかを、役割だけでなく一人ひとりの心理まで込めて模擬できる。実在のメンバーをモデル化して試す応用も
- **アライメント**。「感情を与えても非合理的な判断は再現されない」という発見自体が、AIの安全性研究の材料になる

提出物

- コード+全実験の生ログ+テスト132本(`uv sync && uv run pytest` で検証できます)
- リプレイビューワ / 仕組みの解説サイト / 約3分のデモ動画
- どのファイルがどれに当たるかは、リポジトリの **SUBMISSION.md** に対応表があります
- github.com/mizkun/pneuma-lab