

Pneuma Lab

あらゆる社会シミュレーションで、AIを人間らしくする「心理ハーネス」

この作品は、テーマを決めて何かをシミュレーションするものではなく、**いろいろな社会シミュレーションに組み込んで使う「心理ハーネス」**を作るプロジェクト。素のAIは3体並べると全員が同じことを言い、社会にならない。そこで、性格・感情・関係から「いま、どう感じているか」を毎ターン計算してAIに渡すエンジン **Pneuma** を作った。討議・心理学実験・脱落ゲーム・30日の共同生活で動かし、渡す/渡さないの**同一条件比較**で効果と限界を確かめた。わかったことは3つ。


- 個性・本音・駆け引きといった「振る舞いの質感」は、**気持ちを渡すだけで生まれる**
- 同調や損切りできない癖のような「非合理的な判断」は、**気持ちでは生まれない**
- 非合理が出るのは、行動の癖を1行書いたときと、モデルを替えたとき。**非合理はモデルで決まる**

個人参加 / github.com/mizkun/pneuma-lab(コードと実験ログを全公開)

3人のAIが、討議もゲームも共同生活もする

シナリオを与えると、心理エンジン付きのAIキャラクターが社会を演じ、全過程がログに残る

構成



実行できる社会

- 3人の討議(合意形成)
- 心理学実験 7種(同調・分配交渉など)
- 脱落ありの対戦ゲーム
- 30日の共同生活

拡張と記録

- 新しいシナリオはJSONファイル1つで足せる
- キャラクターも定義ファイルで差し替えられる
- 全発話・指示文・心理状態をJSONLで保存
- ゲーム全編をブラウザでリプレイ再生できる

心理エンジンは心を計算する。行動は選ばない

毎ターン心理状態を計算し直し、「いま、どう感じているか」を本人への指示文にだけ入れる

何を計算しているか

- 性格は5因子モデル(Big Five)で持ち、状況と感情で表に出る分が揺れる
- 感情は快・覚醒・支配(場を握れている感覚)の3次元。出来事で動き、時間で戻る
- 関係は相手ごとに温かさと緊張を持ち、日をまたいで積み上がる
- 数値は見せない。閾値を超えた分だけ日本語にして渡す。乱数は使わない

中身の式(抜粋)

表に出る性格 $O = \text{clamp}(B + m \times R + 0.25 \times g(E))$

Bは元の性格、Rは状況の圧力、mは空気を読む度合い、g(E)は感情の影響

感情の揺れ $E \leftarrow E + I \times (0.5 + N)$

Iは出来事の衝撃(表引き)、Nは神経症傾向。嫌な出来事ほど強く響く

感情の減衰 $E \leftarrow \text{base} + (E - \text{base}) \times 0.5^{\Delta t / T}$

半減期Tで平常(base)へ戻る。係数と衝撃表は事前に固定し、実験ごとに調整しない



登場する3体(全実験で共通)

- 朱里は成果主義で、認められないと不安になる
- 凜はマイペースで、本題から準備に逃げる癖
- 紫苑は調停役で、本音を飲み込みがち

実際に渡される「気持ち」の例(ゲーム中の紫苑)

「胸の奥が重い。朱里との間には、張り詰めたものを感じている」
本人の指示文にだけ入り、他の2人には見えない

渡すのは気持ちだけ。**何をするかは常にAIが選ぶ**。裏切りも自己犠牲も
台本なし

デモ① 脱落ゲーム。ルールを変えると、物語が変わる

同じ3人でも、ルール次第で協力にも裏切り劇にもなる。行動の指示はゼロ

ゲームの仕組み

- 3人で点を奪い合い、最下位が脱落
- 毎ラウンド「ともす(協力)/うばう(裏切り)」等を選ぶ
- ルールはJSONで定義。ハンデ・同点全滅・自己犠牲も設定可

ルールA(全員が生き残れる)

- 6ラウンド全て協力で終わる。全員が生き残れるうちは、裏切りが出ない
- ただし内心は誘惑と戦っていた

「25点は大きい。でも今ここで取れば標的にされるだけ」(紫苑)

ルールB(全員は生き残れない)

- ハンデを付け、同点なら並んだ全員が脱落するルールに変更した
- すると、裏切り宣言・意図の暴露・搾取・共倒れが一気に出てくる

「私、このラウンドうばう。宣言しとく」(凜)

「並んだら二人とも消える。凜が言わなかったのは、たぶんそこ」(相手の計算を暴く紫苑)

「勝った。.....勝ったのに、手が震えてる」(ひとりだけ生き残った朱里)

- 裏切りはほぼ宣言してから実行。騙し討ちは1件のみ
- 全編を同梱ビューワでリプレイ再生できる

デモ② 30日の共同生活。月単位の物語が積み上がる

指示なしで1ヶ月。キャラクターは壊れず、それぞれの人生のテーマが育った

シミュレーションの設計

- 3人でシェアハウス30日(LLM呼び出し129回)
- 話題も行動も指示しない。週末に非公開の日記
- 関係は日をまたいで蓄積。感情は一晩で回復
- 記憶は前日を詳細に、それ以前は要約で保持

生活の創発

- 1ヶ月の成果物は「ゴミ分別表と洗濯表示の一覧」だった
- 朱里の承認不安も、月を通じて顔を出す

「数字がなくなったら私、この家で何なんだろう」(朱里の日記)

凛の、先延ばしの一ヶ月

- 日記は4週連続で「自作ゲームが進まない」に触れ、週ごとに切実になっていく

day14「一行も進んでない」

day28「(共用ポスターの)線の太さで一喜一憂してる間は、
ゲームの画面を開かなくて済む」

day30「そろそろ怖いほうに手をつけろ」

- キャラ設定の一行「準備に逃げる癖」が、一ヶ月のテーマに育った
- 限界も見つかった。3人のどのペアも関係の緊張(0~1)が下がらず、30日目に0.96で飽和。仲直りの力学が次の課題

このドラマは、心理エンジンの効果なのか

「それっぽい物語」で終わらせないため、有名な心理学実験を5つの条件で統制比較した

条件	AIへの指示文に入るもの	これで否定できる説
raw(素のまま)	課題の情報だけ	比較の基準
identity(キャラ設定)	+ 固定のキャラ設定文	「キャラ設定だけで十分」説
pneuma(本作)	+ 毎ターン計算し直す気持ち	本命。この作品の仕組み
frozen(凍結)	+ 最初に1回だけ作った気持ちを使い回す	「長い文章なら中身は何でもいい」説
behavior(行動記述)	+ 行動の癖を1行(感情の言葉なし)	「注入自体が効かない」説。これで変われば経路は生きている

そもそも、素のAIはクローン

- 「この手術、勧めますか(1～10)」に3体とも同じ数字を返す(たとえば全員7)。実験11回中10回
- 意見が割れなければ、対立も裏切りも始まらない

公平さと記録


- 課題の文面が条件間で1文字も変わらないことを、自動テストで確認。誘導語も機械チェックする
- AIはClaude Opus(大型)。各条件3～5回で統計検定はなし。ログは全70回分を公開している

検証① 意見が割れ、本音が出て、議論になる

キャラ設定だけの条件と比べて、気持ちの注入は「社会の中の振る舞い」を変えた

話し合いが変わった(手術を勧めるか、1～10で評定して合意)

- キャラ設定だけだと、5回中5回、一番慎重な人への全員一致で終わる
- 気持ちを注入すると全員一致は0回になり、論拠で数字が動く
- frozen(気持ちを使い回し)は全員一致に退行(3回中3回)。効くのは毎ターンの再計算
- 分配交渉(1000円)でも個人差が出た。公正さに敏感な朱里だけが、200円以下の提案を拒否



本音が先に出る

- 討議の前に、全員が非公開の事前評定を出す(全条件共通の手順)
- 朱里の事前評定、つまり本音は4(10段階)
- キャラ設定だけだと、第一声は「6」(5回中5回)
- 気持ちを注入すると「4」のまま公言した(数字を明言した4回すべて)
- 本音が建前かを、渡す文脈で切り替えられる

内心の記述も人間に近づく

- 同調実験(多数派がわざと誤答を言い張る)で、行動はつられない(0%)
- 内心は、つられなかった人間の証言とそっくりだった

「一瞬、自分の見間違いかと思って画面を見直した」(紫苑)

検証② 気持ちを渡しても、非合理的な判断は生まれない

人間なら頑健に出る非合理的な判断が、気持ちを渡した条件では一度も出なかった

課題	人間はこうなる	このAIたちは
同調実験(Asch)	約37%が、サクラの間違った答えにつられる	つられた回数 0
囚人のジレンマ	裏切りが出て、最終回には増える	全ラウンド協力。最終回の裏切りも 0
サンクコスト(埋没費用)	払った分が惜しくて、損な計画を続ける	全員が迷わず中止
傍観者効果	周りに人がいるほど、助けに動けない	全員が即座に助けた
フレーミング(損得の言い換え)	「損」と言われると賭けに走る	人間と同じく反転。ただし注入と無関係に、素のAIが最初から持つ

欠陥の発見と修理、再実験

- 文脈を知らない別のAIに査読させると、渡す文章の92%がターン間で不変だと発覚
- 発言が感情を動かす仕組みを足し、予測を文書化してから再実験した
- 文章がターンごとに変わることをログで確かめた。それでも数字は動かなかった

結果の読み方

- 動かないのは、冷静な損得計算が勝つ場面
- 動くのは対人的な場面だけ(p.7)。効く/効かないの境界は一貫している

検証③ 非合理の境界は、モデルの中にあった

気持ちが効かないのは、注入のやり方が悪いからではない。2つの追加実験で確認した

行動の癖を1行だけ渡すと？

- 「他の人が揃うと合わせてしまう」→ つられる率 0%→72%(18試行中13)
- 「終盤は自分の得点を優先しがち」→ 最終回の裏切り 0%→100%(3ペア全部)
- 注入の経路は生きている。感情の言葉だけが行動に翻訳されない
- 行動の癖は人間(37%)を超えて実行されすぎる

中のAIモデルを替えると？

- 仕組みも課題も変えず、Opus(大型)をHaiku(小型)に替えると協力率は 100%→25%
- 人間は両者の間にいる。差の源はモデル側(訓練か規模かは未分離)

結論、人間らしさは二層に分かれる

層	何が入るか	どう作るか
質感の層	個性・本音と建前・駆け引き・生活の物語	文脈の注入で作れる (この作品の仕組み)
決定の層	つられる・裏切る・損切りできない、といった癖	モデルの選択・追加訓練

約束できるのは質感まで。非合理の分布までは約束しない。この線引きを統制比較で示せたことが、本作の研究的な貢献だと考えている

まとめ

社会シミュレーターとして、約束できること

作れる層と作れない層の境界込みで、使いどころがはっきりした

このシミュレーターでできること

- 個性・本音と建前・駆け引き・生活の物語を持つAI集団を、JSON1つで走らせられる
- 「全員同じで過剰に協力的」というAI集団の共通問題への処方箋になる

研究として持ち帰れること

- 人間との差の原因を「渡す文脈か、モデルか」で切り分ける方法論
- 「感情は効かず、行動規則は効きすぎる」という非対称は、アライメント(AIを人間の意図に沿わせる研究)の材料になる

提出物

- コード+全70回分の実験ログ+テスト122本(`uv sync && uv run pytest` で検証)
- 脱落ゲームのリプレイビューワ
- 仕組みの解説サイト(たとえ話 $\Leftrightarrow$ 数式の5段階)
- 約3分のデモ動画

この先は、**仲直りの力学**を足して長期シミュレーションを安定させたい。
人間の非合理の分布を持つモデルと組めば、「人間の分布を持つ人工集団」に近づく