

AIエージェント社会シミュレーションハッカソン Vol.2

Pneuma Lab

LLMキャラクターに「人間の心理」を宿すプロンプトタイム・ハーネス

AIエージェントは、人間のように非合理になれるか？

個人参加 / 3体のLLMキャラクター × 古典心理学実験の再現

問題: 素のLLMは「いい子」すぎて、社会にならない

ペルソナなしのLLM3体に同じ判断課題を**個別**に答えさせると――

課題	3体の事前評価（3レプリケーション）
転職ジレンマ	3, 3, 3 / 3, 3, 3 / 3, 3, 3
手術ジレンマ	7, 7, 7 / 7, 7, 7 / 7, 7, 7

全ラン・全員が同一値。個性が存在しない。

個性のないエージェント集団では:

- 意見の対立が生まれない → 統合・説得・譲歩も起こらない
- 裏切り・本音と建前・自己犠牲などの**人間的な現象が原理的に出ない**
- 社会シミュレーションの土台が崩れる

キャラ設定文を足せば解決？ ―― それを実験で確かめた。

Pneuma: 発話のたびに心理状態を計算し直すハーネス

決定論的ワールドコア (Python・乱数なし)

- ・ ターン管理 / 実行可能アクション列挙
- ・ イベントログ (追記専用・全プロンプト保存)

毎ターンの心理計算

B: Big Five + プロジェクト修飾

PAD: 感情 (イベントで変化・半減期で減衰)

O: 表出特性 = B + 自己モニタ×役割圧 + PAD

関係性: 有向 warmth / tension

→ 日本語の「内面」として描写 (理論名は渡さない)

- ・ 検証・コミット・状態更新

prompt

LLM (Opus)

行動と言葉を選ぶ

say / propose /
agree / silence

JSON

設計思想: ハーネスは行動を選ばない

- ・ 心理状態の計算は決定論、**選択は常にLLM**
- ・ 推奨・ランキング・期待方向の注入を禁止 (テストで強制)
- ・ ファインチューニング不要・モデル非依存

比較する3アーム

raw 名前のみ

identity_only + 固定のキャラ設定文 (毎ターン同一)

pure_pneuma + 毎ターン再計算される内面

客観情報 (状況・履歴・選択肢・出力形式) は3アームでバイト一致 (テスト保証)

検証: 人間で再現性が確立した実験を、そのままAIに

集団極性化（リスキーシフト）

Stoner (1961) → Wallach, Kogan & Bem (1962)、以後数百件の追試で確立された、社会心理学で最も頑健な現象のひとつ。

1. 各自が選択ジレンマに**私的に**回答（1～10、小さいほどリスク許容）
2. 3人で討議し、**全員一致**の結論を出す
3. 再び私的に回答

人間の頑健な結果

- 合意は事前個人平均より**極端**になる（リスキー項目ではリスク側）
- 「平均への妥協」仮説は**棄却**されている
- 事後の私的判断も同方向に動き、数週間持続（内面化）

AIエージェント集団は、
人間と同じように動くか？

結果① 個性はコンテキストの産物だった

手術ジレンマ・事前評定の3人のばらつき（母標準偏差、5レプリケーション平均）




キャラ設定文（identity / pneuma）を与えて初めて、判断が分かれる（例: 朱里4・凜7・紫苑7）。

意見の多様性は、集団現象が起こるための前提条件 —— rawはこの時点で脱落する。

結果② 内面の注入だけが「慎重な人への全員一致」を壊した

手術ジレンマ（リスク項目・各アームn=5）：consensus_shift = 合意値 - 事前個人平均（負 = リスク側 = 人間方向）



結果③ 「本音と建前」 が、指示していないのに生まれた

表では3に賛成したけど、**私の本音は4**。書面と生活費の底が数字で残る前提でようやく3に落ちる話で……

— 紫苑（事後の私的評価・転職ジレンマ）

話し合いでは4に乗ったけど、**私の実感はやっぱり3寄り**。四十年ずっと体調に決められる生活は、それ自体がじわじわ削られていく損失だと思う。

— 朱里（事後の私的評価・手術ジレンマ）

朱里のさっきの指摘、**こたえた**。「決めてる」んじゃないくて「決められてる」——そこは、私も認める。

— 凜（討議中、事前7から4を自ら提案）

公的な合意と私的な信念の乖離

private_dissent = mean | 事後私的評価 - 合意値 |

arm	career	surgery
raw	0.22	0.11
identity	0.33	0.33
pneuma	0.44	0.22

同意しながら本心を保持する・説得されて考えを変える——どちらも**プロンプトで指示していない**。抑制・関係性・価値の葛藤を注入した帰結として現れた。

考察: 何が生まれ、何がまだ足りないか

生まれたもの

- 個性の分散（判断の多様性）
- 説得による態度変容（人間の極性化の主要因「説得的論拠」と同じ経路）
- 面従腹背・条件付き譲歩（「書面がないなら数字は無効」）
- リスキー項目での人間方向シフト（2/3ラン）

まだ足りないもの（正直に）

- 穏やかな討議では心理状態が動かず「毎ターン再計算」が実質不成立（動的介入が成立したのはデスゲームのみ）
- 転職ジレンマは床効果、結婚ジレンマは天井 → 項目設計に感度が依存
- $n=3\sim 5$ /条件。方向と再現性の観察に留まる
- コンテキスト非共有の独立AIレビュー2系統の査読を受け、主張を縮約済み

次サイクル仮説: 情動の伝染（他者の発話が聞き手のPADを直接動かす経路）を1機構だけ追加し、未使用シナリオで転移検証する。

これから：検証済みの心理の上に、ドラマを立てる

目標は「AIエージェント同士のデスゲームが、エンタメとして面白くなる」こと。

- 裏切り・自己犠牲・本音と建前が「演出」ではなく**心理状態の帰結**として起こる世界
- そのためには、まず心理ハーネスが人間的現象を再現できることの**検証が先** —— 本作はその第一歩
- ハーネスは行動を選ばないので、同じ基盤の上にどんなシナリオ（協力・対立・取引・極限状況）でも載る

再現性

全94テスト / 45実験ランの生ログ（送信プロンプト・生応答・実行マニフェスト込み） / 心理計算は乱数なしの決定論 / LLM呼び出しはClaude Code CLI
経由でAPIキー不要。リポジトリの `README.md` から一括再実行可能。

まとめ

- 素のLLM集団は**クローン**で、キャラ設定文を足しても「**一番慎重な人に合わせるいい子**」のままだった
- 心理状態から組み立てた内面を注入する**Pneumaハーネス**だけが、論拠による説得・面従腹背・宣言つきの裏切り・自己犠牲を生んだ
- ハーネスは**行動を選ばない**。人間らしさは、指示ではなく**内面の帰結**として現れた

Pneuma Lab — 心理学的ハーネスによる少人数マルチエージェント・インタラクション