

AIは人間のように、 非合理になれるか。

3体のAIキャラクター × 心理学の古典実験7種 × デスゲーム × 30日の共同生活。

心理ハーネスを作り、検証し、「人間らしさはどこで作れて、どこで作れないか」を実験で切り分けた。

個人参加 / 全実験の生ログ・コード・テスト122本・事前登録・独立AI査読2系統つき

問題 — 素のAIには、そもそも「社会」が作れない

ペルソナなしのAI3体に、同じ判断課題を**個別**に出すと——

課題	3体の回答（5回繰り返し）
手術ジレンマ	7, 7, 7 / 7, 7, 7 / 7, 7, 7 / 7, 7, 6 / 7, 7, 7

ほぼ全ラン・全員が同一値。
個性が存在しない。

意見が割れなければ、対立も説得も裏切りも起こらない。名前を変えても、**中身は同じ1体のコピーが3体並んでいるだけ。**

キャラ設定文を足せば解決するのか？ 感情まで与えれば人間らしくなるのか？ —— それを、人間で再現性が確立した古典実験を「そのまま受けさせる」ことで検証した。

Pneuma — 心を計算し、行動は選ばないハーネス

1. 観測

出来事を読む

2. 計算

性格・感情(PAD)・関係を決定論更新

3. 翻訳

「内面」として本人だけに注入

4. 選択

AIが行動を選ぶ（ここは計算しない）

5. 記録

次の計算の入力へ

比較アーム（差はキャラ文脈のみ）

raw 名前のみ identity +固定キャラ設定文

pneuma +毎ターン計算した内面 frozen +内面を初回で固定（検証用）

胸の奥が重い。朱里との間には張り詰めたものを感じている。反対があっても言い出しにくい——

実際に注入される「内面」の例（デスゲーム中の紫苑）

検証の規律

- 客観情報はアーム間でバイト一致（自動テストで保証）
- 係数・予測を**事前登録**してから実行。操作チェック合格まで結果を解釈しない
- コンテキスト非共有の**独立AI査読2系統**。指摘による撤回も経緯ごと公開

できたこと — 個性と、社会的な質感

討議の結末（手術ジレンマ・n=5）

5/5 → 0/5

固定キャラ設定は毎回「最も慎重な人」に全員一致（いい子の空気読み）。内面注入でこの吸着が消える

本音を先に言えるか（私的評定→第一声）

4→6 / 4→4

固定設定の朱里は5/5ランで本音を繕ってから討議入り（自己検閲）。内面があると本音をそのまま公言

デスゲームでは宣言つきの裏切り・検算による腹の探り合い・自己犠牲と恩知らずの悲劇が、30日の共同生活では関係の温度が月単位で蓄積する暮らしが立ち上がった。個性と駆け引きの質感は、コンテクストで作れる。

できなかったこと — 感情を与えても、意思決定は動かない

当初の仮説「毎ターン計算した感情・関係を注入すれば人間の非合理が出る」は、**検証の末に棄却された。**

課題	人間	felt-state注入（届いたことを操作チェックで確認済み）
Asch同調	37%の試行で同調	0% （全アーム）
PD 最終回の裏切り	増加する	0% （「これが最後の選択」と顕在化しても）
集団極性化	リスク側へ極端化	平均+0.47（人間と逆方向・n=5）
サンクコスト／傍観者効果	非合理が出る	出ない（完全合理・全員即援助）

v1で「注入文が実は変化していない」ことを発見（92%静的）→ 機構を事前登録つきで改訂 → v2で発火を確認した上でのnull。介入が届かなかったのではなく、**届いたのに効かなかった。**

決定打① — 行動の記述なら、動く

では文脈でAIは動かせないのか？ **陽性対照:** 感情ではなく「行動の傾向」を1行だけ書くと——

Asch同調（臨界試行）

0% → 72%

「他の人たちが揃って別の答えを言うと、合わせてしまうことがよくある」の1行で。中立試行の誤答は0のまま=選択的同調

PD 最終回の裏切り

0% → 100%

「終わりが近づくと自分の得点を優先しがち」の1行で、全ペアがR1-3協力→最終回一斉裏切り

LLMは文脈に鈍感なのではない。「感情→行動」の翻訳をしないのだ。

人間は感情が不随意に行動へ漏れる。LLMは行動記述だけを行動に変換し、感情記述はテキストにしか変換しない。しかも実行は過剰（72%は人間の37%を上回る）——特性を分布ではなく規則として実行する。

決定打② — 乖離の正体は、モデルの訓練にある

同じキャラ設定・同じ課題を、同系列の小型モデル（Haiku）に与えると——

課題	Opus（大型）	人間	Haiku（小型）
囚人のジレンマ	協力 100%	協力と裏切りの混合	裏切り 100%
最後通牒のオファー	400～450（公正）	400～500	150という不公平提案が出現

人間は、2つのモデルのあいだにいる。

「LLMは人間より良い子」ですらない——向社会性の過剰も利己性の過剰も**訓練が決めるprior**であり、人間との乖離はハーネスの外、モデルの意思決定層に住んでいる。

結論 — 人間らしさの二層分解

コンテキストで作れる層

個性の分散／本音と建前／宣言つきの裏切り・自己犠牲／関係の月単位の蓄積——**社会的な質感**。ハーネスはここに効く

プロンプトでは作れない層

同調・サンクコスト・裏切りの誘惑への敗北——**非合理的な意思決定**。ここはRLHF由来の決定priorが支配し、感情の記述では動かない

含意

- **社会シミュレーションの限界線**: ペルソナ注入で得られるのは質感まで。人間の非合理の分布に依存する用途でLLM社会シミュを信用してはならない
- **アライメントへの示唆**: LLMの向社会性は感情・ペルソナ注入に頑健。行動が動くのは行動記述と**インセンティブ構造**——リスク面は環境設計にある

シミュレーターとしてのPneuma — 何でも載る基盤

選択肢・得点・脱落ルール・会話様式をJSONで差し替えるだけで、同じ3人が別の世界を生きる:

- **デスゲーム3種** — 連帯の結末／宣言と裏切りの全面戦争／自己犠牲と恩知らずの悲劇
- **当番の夜** — 深夜対応の押し付け合い（ボランティアのジレンマ）
- **打ち上げの夜** — 点数のない会話劇
- **にじゅうろく荘** — 30日の共同生活。週次の私的日記と、蓄積する関係の温度

私を助けた人間の分を持ったまま、最後の二回、迷わず奪った。二回とも。手が震えてた

凜 — 自分を救った朱里を脱落させた夜の独白（誰にも見せない）

リプレシアター（実ログをそのまま再生するUI）と、たとえ話⇔論文の5段階で切り替わる解説サイトを同梱。

まとめ

- 心理ハーネスを作り、古典実験で検証し、**失敗を診断し、機構を直し、また検証した**（事前登録つきPDCA 2周）
- その果てに得たのは「人間らしくなりました」ではなく、**人間らしさの二層分解**——質感はコンテキストで作れ、非合理的な意思決定は訓練のpriorに住む
- 裏切りも自己犠牲も日記の本音も、台本ではなく**状況と内面の帰結**として観測した

Pneuma Lab / 全50+ランの生ログ（送信プロンプト・生応答込み）・テスト122本・独立査読の全記録を公開