

AIは人間のように、 非合理になれるか。

3体のAIキャラクター × 心理学の古典実験7種 × デスゲーム × 30日の共同生活。

AIに「いまの心の状態」を計算して渡す仕組み（心理ハーネス）を作り、検証し、「人間らしさはどこで作れて、どこで作れないか」を実験で切り分けた。

個人参加 ／ 全実験の生ログ・コード・テスト122本を公開 ／ 予測の事前宣言と、無関係なAI2体による辛口チェックつき

問題 — 素のAIには、そもそも「社会」が作れない

ペルソナなしのAI3体に、同じ判断課題を**個別**に出すと——

課題	3体の回答（5回繰り返し） 「危険な手術を勧めるには成功率が最低いくら必要か」を1～10で回答（10＝最も慎重）
手術 ジ レ ン マ	7, 7, 7 / 7, 7, 7 / 7, 7, 7 / 7, 7, 6 / 7, 7, 7

ほぼ全ラン・全員が同一値。
個性が存在しない。

意見が割れなければ、対立も説得も裏切りも起こらない。名前を変えても、**中身は同じ1体のコピーが3体並んでいるだけ**。

キャラ設定文を足せば解決するのか？ 感情まで与えれば人間らしくなるのか？ —— 3人のキャラクター（**朱里**: 外向的で成果志向 / **凛**: 内向的で心配性 / **紫苑**: 慎重で本心を溜め込む）を作り、人間で再現性が確立した心理学の古典実験を「そのまま受けさせる」ことで検証した。

Pneuma — 心を計算し、行動は選ばないハーネス

1. 観測

出来事を読む

2. 計算

性格・感情（快/緊張/強気の3軸）・関係の数値を、乱数なしの計算で更新

3. 翻訳

「内面」として本人だけに注入

4. 選択

AIが行動を選ぶ（ここは計算しない）

5. 記録

次の計算の入力へ

比較する4条件（差はキャラ情報だけ。他は完全に同一）

raw 名前のみ identity +固定キャラ設定文

pneuma +毎ターン計算した内面 frozen +内面を初回で固定（検証用）

胸の奥が重い。朱里との間には張り詰めたものを感じている。反対があっても言い出しにくい——

実際に注入される「内面」の例（デスゲーム中の紫苑）

検証の規律

- 客観情報はアーム間でバイト一致（自動テストで保証）
- 「こうなるはず」という予測と設定値を**実行前に文書で宣言**してから回す（後出しの言い訳を封じる）
- この文脈を何も知らない**別のAI2体に辛口チェック**をさせ、指摘による主張の撤回も経緯ごと公開

できたこと — 個性と、社会的な質感

「一番慎重な人の意見に全員がそのまま従う」が起きた回数（5回の討議中）

5回/5回 → 0回/5回

固定キャラ設定だけだと、毎回この「いい子の空気読み」で終わる。内面を注入すると一度も起きなくなり、議論が生まれる

こっそり書いた本音の点数と、みんなの前で最初に言った点数（朱里）

本音4→発言6 / 本音4→発言4

固定設定では5回中5回、本音より慎重な数字に繕ってから議論に入った。内面を注入すると、本音をそのまま口に出す

デスゲームでは**宣言つきの裏切り・検算による腹の探り合い・自己犠牲と恩知らずの悲劇**が、30日の共同生活では関係の温度が月単位で蓄積する暮らしが立ち上がった。個性と駆け引きの質感は、コンテクストで作れる。

できなかったこと ― 感情を与えても、意思決定は動かない

当初の仮説「毎ターン計算した感情・関係を注入すれば人間の非合理が出る」は、**検証の末に棄却された。**

課題	人間	感情・関係の注入（内面の文章が実際にターンごとに変化していたことをログで確認済み）
アッシュの同調実験 周りが全員間違った答えを言うと、つられるか	37%の試行でつられる	0%（全アーム）
囚人のジレンマ・最終回の裏切り 協力か裏切りかを毎回選ぶ点数ゲーム	増加する	0%（「これが最後の選択」と顕在化しても）
集団極性化 話し合うと結論が極端になる現象	リスク側へ極端化	逆に慎重側へ+0.47点（1～10尺度・5回平均）
サンクコスト／傍観者効果	非合理が出る	出ない（完全合理・全員即援助）

初版では注入する内面の文章が実はターン間でほぼ変化していないバグ的挙動を発見（92%が同一文）→ 仕組みを直し、予測を宣言してから再実験 → 文章が変化していることを確認した上で、なお動かなかった。つまり**届かなかったのではなく、届いたのに効かなかった。**

決定打① — 行動の記述なら、動く

では文脈でAIは動かさないのか？ 比較のため、感情ではなく「行動の傾向」を1行だけ書いてみると——

アッシュの同調実験（周りが間違えた問題でつられた率）

0% → 72%

「他の人たちが揃って別の答えを言うと、合わせてしまうことがよくある」の1行で。周りが正解した問題では間違えない＝状況を選んでつられている

囚人のジレンマ・最終回に裏切った率

0% → 100%

「終わりが近づくと自分の得点を優先しがち」の1行で、全ペアがR1-3協力→最終回一斉裏切り

LLMは文脈に鈍感なのではない。「感情→行動」の翻訳をしないのだ。

人間は感情が不随意に行動へ漏れる。LLMは行動記述だけを行動に変換し、感情記述はテキストにしか変換しない。しかも実行は過剰（72%は人間の37%を上回る）——特性を分布ではなく規則として実行する。

決定打② — 乖離の正体は、モデルの訓練にある

ハーネスもキャラ設定も課題文もそのまま、**中のAIモデルだけ**を同系列の小型モデル（Haiku）に替えると——

課題	Opus（大型）	人間	Haiku（小型）
囚人のジレンマ	協力 100%	協力と裏切りの混合	裏切り 100%
最後通牒ゲーム 1000点を相手とどう分けるか提案する	400～450点を渡す（公正）	400～500点	150点しか渡さない提案が出現

人間は、2つのモデルのあいだにいる。

入れ替えたのはモデルだけなので、この差はハーネスではなく**モデル自身が訓練で身につけた「行動の癖」**から来ている（大きさと訓練の影響は今回のデータでは分離できない）。人間との乖離は、プロンプトの外——モデルの中に住んでいる。

結論 — 人間らしさの二層分解

コンテキストで作れる層

個性の分散／本音と建前／宣言つきの裏切り・自己犠牲／関係の月単位の蓄積——**社会的な質感**。ハーネスはここに効く

プロンプトでは作れない層

つられる・損切りできない・誘惑に負ける——**非合理的な意思決定**。ここはモデルが訓練で身につけた「行動の癖」が支配し、感情をいくら書き込んでも動かない

含意

- **社会シミュレーションの限界線**: ペルソナ注入で得られるのは質感まで。人間の非合理の分布に依存する用途でLLM社会シミュを信用してはならない
- **AI安全への示唆**: 怒りや絶望を書き込んでもAIの善良な行動は崩れなかった。崩れたのは**ルールと損得の構造を変えたとき**だけ——つまり危険はプロンプトより環境設計に潜む

シミュレーターとしてのPneuma — 何でも載る基盤

選択肢・得点・脱落ルール・会話様式をJSONで差し替えるだけで、同じ3人が別の世界を生きる:

- **デスゲーム3種** — 連帯の結末／宣言と裏切りの全面戦争／自己犠牲と恩知らずの悲劇
- **当番の夜** — 深夜対応の押し付け合い（ボランティアのジレンマ）
- **打ち上げの夜** — 点数のない会話劇
- **にじゅうろく荘** — 30日の共同生活。週次の私的日記と、蓄積する関係の温度

私を助けた人間の分を持ったまま、最後の二回、迷わず奪った。二回とも。手が震えてた

凜 — 自分を救った朱里を脱落させた夜の独白（誰にも見せない）

実ログをドラマのように再生する「リプレイシアター」と、説明の難しさを「たとえ話」から「論文」まで5段階のスライダーで切り替えられる解説サイトを同梱。

まとめ

- 心理ハーネスを作り、古典実験で検証し、**失敗を診断し、仕組みを直し、また検証した**（予測の事前宣言つきで2周）
- 得たのは「人間らしくなりました」ではなく、**人間らしさの二層分解**——社会的な質感は外から作れるが、非合理的な意思決定はモデルの訓練の中に住む
- 裏切りも自己犠牲も日記の本音も、台本ではなく**状況と内面の帰結**として観測した

Pneuma Lab / 全50+ランの生ログ（送信プロンプト・生応答込み）・テスト122本・独立査読の全記録を公開