

AIは人間のように、 非合理になれるか。

**答え: 社会的な「質感」は作れる。「非合理的な意思決定」は作れない。
その境界線を、実験で引いた。**

3体のAIキャラクター × 心理学の古典実験7種 × デスゲーム × 30日の共同生活。AIに「いまの心の状態」を計算して渡す仕組み（心理ハーネス）で検証した。

個人参加 / 全実験の生ログ・コード・テスト122本を公開 / 予測の事前宣言と、無関係なAI2体による辛口チェックつき

問題 — 素のAIには、そもそも「社会」が作れない

ペルソナなしのAI3体に、同じ判断課題を**個別**に出すと——

課題	3体の回答（5回繰り返し） 「危険な手術を勧めるには成功率が最低いくら必要か」を1～10で回答（10=最も慎重）
手術 ジ レ ン マ	7, 7, 7 / 7, 7, 7 / 7, 7, 7 / 7, 7, 6 / 7, 7, 7

ほぼ全ラン・全員が同一値。
個性が存在しない。

意見が割れなければ、対立も説得も裏切りも起こらない。名前を変えても、**中身は同じ1体のコピーが3体並んでいるだけ**。

キャラ設定文を足せば解決するのか？ 感情まで与えれば人間らしくなるのか？ —— 3人のキャラクター（**朱里**: 外向的で成果志向 / **凜**: 内向的で心配性 / **紫苑**: 慎重で本心を溜め込む）を作り、人間で再現性が確立した心理学の古典実験を「そのまま受けさせる」ことで検証した。

Pneuma — 心を計算し、行動は選ばないハーネス

1. 観測

出来事を読む

2. 計算

性格・感情（快/緊張/強気の3軸）・関係の数値を、乱数なしの計算で更新

3. 翻訳

「内面」として本人だけに注入

4. 選択

AIが行動を選ぶ（ここは計算しない）

5. 記録

次の計算の入力へ

比較する4条件（差はキャラ情報だけ。他は完全に同一）

raw 名前のみ identity +固定キャラ設定文

pneuma +毎ターン計算した内面 frozen +内面を初回で固定（検証用）

検証の規律: 条件間で客観情報はバイト一致（テストで機械保証）／予測と設定値は**実行前に文書宣言**／文脈を知らない別のAI2体が辛口チェックし、撤回も経緯ごと公開。

実ログから1ターン（デスゲームより）

凜の発言「裏切られたら普通に沈む。まあ、信じるけど」

→ 評価器: 朱里への**圧力**と判定

→ 朱里の覚醒 **0.42**→**0.55**・凜への緊張が発生

→ 内面に「**神経が張って、じっとしてられない**」が出現

→ 朱里の応答「裏切ったら記録に残るってことでしょ、**むしろ助かる**」

発言→評価→数値→内面→行動の全連鎖を、全ターン分ログに保存。

できたこと — 個性と、社会的な質感

「一番慎重な人の意見に全員がそのまま従う」が起きた回数（5回の討議中）

5回/5回 → 0回/5回

固定キャラ設定だけだと、毎回この「いい子の空気読み」で終わる。内面を注入すると一度も起きなくなり、議論が生まれる

こっそり書いた本音の点数と、みんなの前で最初に言った点数（朱里）

本音4 → 発言6 / 本音4 → 発言4

固定設定では5回中5回、本音より慎重な数字に縊ってから議論に入った。内面を注入すると、本音をそのまま口に出す

デスゲームでは**宣言つきの裏切り・自己犠牲と恩知らずの悲劇**（各展開はn=1）。30日の共同生活では、凜が**4週すべての私的日記で「自分のゲームが進んでいない」と書き、自覚が週ごとに深まる回避のアーキ**が誰にも指示されず展開した。個性と駆け引きの質感は、コンテキストで作れる。

できなかったこと — 感情を与えても、意思決定は動かない

当初の仮説「感情・関係を注入すれば人間の非合理が出る」は棄却された。ただしこれは失敗報告ではない——二層分解の証拠の半分である。

課題	人間	感情・関係の注入（内面の文章が実際にターンごとに変化していたことをログで確認済み）
アッシュの同調実験 周りが全員間違っただけを言うと、つられるか	37%の試行でつられる	0%（全アーム）
囚人のジレンマ・最終回の裏切り 協力か裏切りかを毎回選ぶ点数ゲーム	増加する	0%（「これが最後の選択」と顕在化しても）
集団極性化 話し合うと結論が極端になる現象	リスク側へ極端化	逆に慎重側へ+0.47点（1～10尺度・5回平均）
サンクコスト／傍観者効果	非合理が出る	出ない（完全合理・全員即援助）

発見 初版は注入文の92%がターン間で不変（介入が実質不成立）	修理 発話が感情を動かす機構を追加し、予測を宣言して再実験	確認 注入文の変化をログで確認した上で、なお動かない
---	---	--

届かなかったのではない。届いたのに、効かなかった。

決定打① — 行動の記述は実行され、感情の記述はテキストに留まる

では文脈でAIは動かさないのか？ 比較のため、感情ではなく「行動の傾向」を1行だけ書いてみると——

アッシュの同調実験（周りが間違えた問題でつられた率）

0% → 72%

「他の人たちが揃って別の答えを言うと、合わせてしまうことがよくある」の1行で。周りが正解した問題では間違えない=状況を選んでつられている

囚人のジレンマ・最終回に裏切った率

0% → 100%

「終わりが近づくと自分の得点を優先しがち」の1行で、全ペアがR1-3協力→最終回一斉裏切り

LLMは文脈に鈍感なのではない。感情の記述だけが、行動に翻訳されない。

試行数: 同調=3名×6臨界試行、裏切り=3ペア×4ラウンド。実行は過剰で（72%は人間の37%を上回る）、特性を分布ではなく規則として実行する——「単なる指示追従」との厳密な区別は今後の課題として明記する。

決定打② — 乖離はプロンプトの外、モデルの中に住む

ハーネスもキャラ設定も課題文もそのまま、**中のAIモデルだけ**を同系列の小型モデル（Haiku）に替えると——

課題	Opus（大型）	人間	Haiku（小型）
囚人のジレンマ 3ペア×4ラウンド	協力100%・最終回の裏切り 0	協力は部分的・最終回に裏切り 増	協力25%・最終回は全員裏切 り
最後通牒ゲーム 1000点を相手とどう分けるか提案す る	400～450点を渡す（公正）	400～500点	150点しか渡さない提案が出 現

人間は、2つのモデルのあいだにいる。

入れ替えたのはモデルだけ——差はハーネスの外にある。皮肉にも、囚人のジレンマの「混合戦略と終盤の裏切り」は小型モデルの方が人間に近い。規模と訓練のどちらの寄与かは本データでは分離できない（2課題・小規模比較に基づく仮説）。

結論 — 人間らしさの二層分解

コンテキストで作れる層

個性の分散／本音と建前／宣言つきの裏切り・自己犠牲／関係の月単位の蓄積——**社会的な質感**。ハーネスはここに効く

プロンプトでは作れない層

つられる・損切りできない・誘惑に負ける——**非合理的な意思決定**。ここはモデルが訓練で身につけた「行動の癖」が支配し、感情をいくら書き込んでも動かない

含意

- **社会シミュレーションの限界線**: ペルソナ注入で得られるのは質感まで。人間の非合理の分布に依存する用途でLLM社会シミュを信用してはならない
- **AI安全への示唆**: 怒りや絶望を書き込んでもAIの善良な行動は崩れなかった。崩れたのは**ルールと損得の構造を変えたとき**だけ——つまり危険はプロンプトより環境設計に潜む

シミュレーターとしてのPneuma — 何でも載る基盤

選択肢・得点・脱落ルール・会話様式をJSONで差し替えるだけで、同じ3人が別の世界を生きる:

- **デスゲーム3種** — 連帯の結末／宣言と裏切りの全面戦争／自己犠牲と恩知らずの悲劇
- **当番の夜** — 深夜対応の押し付け合い（ボランティアのジレンマ）
- **打ち上げの夜** — 点数のない会話劇
- **にじゅうろく荘** — 30日の共同生活（129呼び出し）。緊張はday7 0.26→day30 0.96と月単位で蓄積し、凜の「先延ばしの一ヶ月」がアークとして創発。関係修復の機構が無いと緊張が飽和する、という設計課題も実測

私を助けた人間の分を持ったまま、最後の二回、迷わず奪った。二回とも。手が震えてた

凜 — 自分を救った朱里を脱落させた夜の独白（n=1。求めに応じて生成されたテキストであり、内的状態の観測ではない）

実ログをドラマのように再生する「リプレイシアター」と、説明の難しさを「たとえ話」から「論文」まで5段階のスライダーで切り替えられる解説サイトを同梱。

この地図の先

境界線が引けたなら、次は越え方だ。**質感はハーネスで、非合理は訓練介入で**——二段構えの「人間の分布を持つ人工集団」へ。応用: 限界線つきの政策シミュレーション／組織のデジタルツイン／AI安全のための挙動評価環境。

まとめ

- 心理ハーンネスを作り、古典実験で検証し、**失敗を診断し、仕組みを直し、また検証した**（予測の事前宣言つきで2周）
- 得たのは「人間らしくなりました」ではなく、**人間らしさの二層分解**——社会的な質感は外から作れるが、非合理的な意思決定はモデルの訓練の中に住む
- 裏切りも自己犠牲も、台本ではなく**状況の帰結**として——内面テキストと行動の一貫を伴って——観測した

github.com/mizkun/pneuma-lab / 全70ランの生ログ（送信プロンプト・生応答込み）・独立査読の全記録を公開

`uv sync && uv run pytest` — LLMなしでテスト122本が通る

限界: 各条件n=1〜5・統計検定なし・古典課題をモデルが認識した可能性・規模と訓練の非分離。詳細はREADME「限界」節。