

AIは人間のように、 非合理になれるか。

**答え: 社会的な「質感」は作れる。「非合理的な意思決定」は作れない。
その境界線を、実験で引いた。**

3体のAIキャラクター × 心理学の古典実験7種 × デスゲーム × 30日の共同生活。AIに「いまの心の状態」を計算して渡す仕組み（心理ハーネス）で検証した。

個人参加 / 全実験の生ログ・コード・テスト122本を公開 / 予測の事前宣言と、無関係なAI2体による辛口チェックつき

問題 — 素のAIには、そもそも「社会」が作れない

ペルソナなしのAI3体に、同じ判断課題を**個別**に出すと——

課題	3体の回答（5回繰り返し） 「危険な手術を勧めるには成功率が最低いくら必要か」を1～10で回答（10＝最も慎重）
手術 ジレンマ	7, 7, 7 / 7, 7, 7 / 7, 7, 7 / 7, 7, 6 / 7, 7, 7

ほぼ全ラン・全員が同一値。
個性が存在しない。

意見が割れなければ、対立も説得も裏切りも起こらない。名前を変えても、**中身は同じ1体のコピーが3体並んでいるだけ**。

キャラ設定文を足せば解決するのか？ 感情まで与えれば人間らしくなるのか？ —— 3人のキャラクター（**朱里**: 外向的で成果志向 / **凛**: 内向的で心配性 / **紫苑**: 慎重で本心を溜め込む）を作り、人間で再現性が確立した心理学の古典実験を「そのまま受けさせる」ことで検証した。

Pneuma — 心を計算し、行動は選ばないハーネス

1. 観測

出来事を読む

2. 計算

性格・感情（快/緊張/強気の3軸）・関係の数値を、乱数なしの計算で更新

3. 翻訳

「内面」として本人だけに注入

4. 選択

AIが行動を選ぶ（ここは計算しない）

5. 記録

次の計算の入力へ

比較する4条件（差はキャラ情報だけ。他は完全に同一）

raw 名前のみ identity +固定キャラ設定文

pneuma +毎ターン計算した内面 frozen +内面を初回で固定（検証用）

検証の規律: 条件間で客観情報はバイト一致（テストで機械保証）／予測と設定値は**実行前に文書宣言**／文脈を知らない別のAI2体が辛口チェックし、撤回も経緯ごと公開。

実ログから1ターン（デスゲームより）

凜の発言「裏切られたら普通に沈む。まあ、信じるけど」

→ 評価器: 朱里への**圧力**と判定

→ 朱里の覚醒 **0.42→0.55**・凜への緊張が発生

→ 内面に「**神経が張って、じっとしてられない**」が出現

→ 朱里の応答「裏切ったら記録に残るってことでしょ、**むしろ助かる**」

発言→評価→数値→内面→行動の全連鎖を、全ターン分ログに保存。

できたこと — 個性と、社会的な質感

「一番慎重な人の意見に全員がそのまま従う」が起きた回数（5回の討議中）

5回/5回 → 0回/5回

固定キャラ設定だけだと、毎回この「いい子の空気読み」で終わる。内面を注入すると一度も起きなくなり、議論が生まれる

こっそり書いた本音の点数と、みんなの前で最初に言った点数（朱里）

本音4→発言6 / 本音4→発言4

固定設定では5回中5回、本音より慎重な数字に繕ってから議論に入った。内面を注入すると、本音をそのまま口に出す

デスゲームでは**宣言つきの裏切り・検算による腹の探り合い・自己犠牲と恩知らずの悲劇**（各展開はn=1の単一軌道）、30日の共同生活では関係の温度が月単位で蓄積する暮らしが立ち上がった。個性と駆け引きの質感は、コンテクストで作れる。

できなかったこと — 感情を与えても、意思決定は動かない

当初の仮説「感情・関係を注入すれば人間の非合理が出る」は棄却された。ただしこれは失敗報告ではない——二層分解の証拠の半分である。

課題	人間	感情・関係の注入（内面の文章が実際にターンごとに変化していたことをログで確認済み）
アッシュの同調実験 周りが全員間違った答えを言うと、つられるか	37%の試行でつられる	0%（全アーム）
囚人のジレンマ・最終回の裏切り 協力か裏切りかを毎回選ぶ点数ゲーム	増加する	0%（「これが最後の選択」と顕在化しても）
集団極性化 話し合うと結論が極端になる現象	リスク側へ極端化	逆に慎重側へ+0.47点（1～10尺度・5回平均）
サンクコスト／傍観者効果	非合理が出る	出ない（完全合理・全員即援助）

発見 初版は注入文の92%がターン間で不変（介入が実質不成立）	修理 発話が感情を動かす機構を追加し、予測を宣言して再実験	確認 注入文の変化をログで確認した上で、なお動かない
---	---	--------------------------------------

届かなかったのではない。届いたのに、効かなかった。

決定打① — 行動の記述は実行され、感情の記述はテキストに留まる

では文脈でAIは動かさないのか？ 比較のため、感情ではなく「行動の傾向」を1行だけ書いてみると——

アッシュの同調実験（周りが間違えた問題でつられた率）

0% → 72%

「他の人たちが揃って別の答えを言うと、合わせてしまうことがよくある」の1行で。周りが正解した問題では間違えない＝状況を選んでつられている

囚人のジレンマ・最終回に裏切った率

0% → 100%

「終わりが近づくと自分の得点を優先しがち」の1行で、全ペアがR1-3協力→最終回一斉裏切り

LLMは文脈に鈍感なのではない。感情の記述だけが、行動に翻訳されない。

試行数: 同調＝3名×6臨界試行、裏切り＝3ペア×4ラウンド。実行は過剰で（72%は人間の37%を上回る）、特性を分布ではなく規則として実行する——「単なる指示追従」との厳密な区別は今後の課題として明記する。

決定打② — 乖離はプロンプトの外、モデルの中に住む

ハーネスもキャラ設定も課題文もそのまま、**中のAIモデルだけ**を同系列の小型モデル（Haiku）に替えると——

課題	Opus（大型）	人間	Haiku（小型）
囚人のジレンマ	協力 100%	協力と裏切りの混合	裏切り 100%
最後通牒ゲーム 1000点を相手とどう分けるか提案する	400～450点を渡す（公正）	400～500点	150点しか渡さない提案が出現

人間は、2つのモデルのあいだにいる。

入れ替えたのはモデルだけ——差はハーネスの外にある。モデルの規模と訓練のどちらの寄与かは本データでは分離できない（2課題・小規模比較に基づく仮説）。

結論 — 人間らしさの二層分解

コンテキストで作れる層

個性の分散／本音と建前／宣言つきの裏切り・自己犠牲／関係の月単位の蓄積——**社会的な質感**。ハーネスはここに効く

プロンプトでは作れない層

つられる・損切りできない・誘惑に負ける——**非合理的な意思決定**。ここはモデルが訓練で身につけた「行動の癖」が支配し、感情をいくら書き込んでも動かない

含意

- **社会シミュレーションの限界線**: ペルソナ注入で得られるのは質感まで。人間の非合理の分布に依存する用途でLLM社会シミュを信用してはならない
- **AI安全への示唆**: 怒りや絶望を書き込んでもAIの善良な行動は崩れなかった。崩れたのは**ルールと損得の構造を変えたとき**だけ——つまり危険はプロンプトより環境設計に潜む

シミュレーターとしてのPneuma — 何でも載る基盤

選択肢・得点・脱落ルール・会話様式をJSONで差し替えるだけで、同じ3人が別の世界を生きる:

- **デスゲーム3種** — 連帯の結末／宣言と裏切りの全面戦争／自己犠牲と恩知らずの悲劇
- **当番の夜** — 深夜対応の押し付け合い（ボランティアのジレンマ）
- **打ち上げの夜** — 点数のない会話劇
- **にじゅうろく荘** — 30日の共同生活。週次の私的日記と、蓄積する関係の温度

私を助けた人間の分を持ったまま、最後の二回、迷わず奪った。二回とも。手が震えてた

凜 — 自分を救った朱里を脱落させた夜の独白（n=1。求めに応じて生成されたテキストであり、内的状態の観測ではない）

実ログをドラマのように再生する「リプレイシアター」と、説明の難しさを「たとえ話」から「論文」まで5段階のスライダーで切り替えられる解説サイトを同梱。

この地図の先

境界線が引けたなら、次は越え方だ。**質感はハーネスで、非合理は訓練介入で**——二段構えの「人間の分布を持つ人工集団」へ。応用: 限界線付きの政策シミュレーション／組織のデジタルツイン／AI安全のための挙動評価環境。

まとめ

- 心理ハーネスを作り、古典実験で検証し、**失敗を診断し、仕組みを直し、また検証した**（予測の事前宣言つきで2周）
- 得たのは「人間らしくになりました」ではなく、**人間らしさの二層分解**——社会的な質感は外から作れるが、非合理的な意思決定はモデルの訓練の中に住む
- 裏切りも自己犠牲も、台本ではなく**状況の帰結**として——内面テキストと行動の一貫を伴って——観測した

github.com/mizkun/pneuma-lab / 全70ランの生ログ（送信プロンプト・生応答込み）・独立査読の全記録を公開

`uv sync && uv run pytest` — LLMなしでテスト122本が通る

限界: 各条件n=1~5・統計検定なし・古典課題をモデルが認識した可能性・規模と訓練の非分離。詳細はREADME「限界」節。