

AIは人間のよう に、 非合理になれるか

答え — 質感は作れる。非合理は作れない / Pneuma Lab・個人参加

素のAIには、個性が存在しない

同じ判断課題(手術を勧めるか、1～10で回答)に、3体がほぼ全ラン同一値で答える

7

1体目

7

2体目

7

3体目

5回繰り返しても、同じ

意見が割れなければ、対立も説得も裏切りも起こらない

Pneuma — 心を計算し、行動は選ばない

毎ターン心理状態を乱数なしの決定論で計算し、「内面」として本人だけのプロンプトに注入する



実際に注入される「内面」の例(デスゲーム中の紫苑)

胸の奥が重い。朱里との間には、張り詰めたものを感じている

条件間の情報一致はテストで保証、予測は実行前に文書で宣言

内面を注入すると、議論が生まれる

「一番慎重な人の意見に、全員がそのまま従って終わる」——固定キャラ設定の討議は毎回これ

固定キャラ設定だけ

5回/5回

毎回、いい子の空気読みで終わる



内面を注入

0回/5回

論拠で人が動く討議に変わる

デスゲームでは宣言つきの裏切りや自己犠牲まで展開した(各n=1)

本音を、先に言えるようになる

私的な本音が4の朱里は、みんなの前の第一声で「6」と繕うか、「4」のまま言うか

固定キャラ設定だけ

本音4 → 発言6

5回中5回、繕ってから議論に入る

内面を注入


本音4 → 発言4

本音を、そのまま口に出す

説得よりも前——議論が始まる前から、内面は行動を変えていた

30日の共同生活 ― 凜の、先延ばしの一ヶ月

シェアハウス30日。誰にも指示せず、4週すべての私的日記で同じ悩みが深まっていく



週次の私的日記(誰にも見せない)からの抜粋

性格の核「準備へ逃げる」が、一ヶ月の人生テーマとして創発した

感情を与えても、意思決定は動かない

同調0%・最終回の裏切り0%——古典心理学実験の非合理は、内面が届いた上で再現しない

1 発見

初版は注入文の92%がターン間で不変——介入が実質成立していなかった

2 修理

発話が感情を動かす機構を追加し、予測を文書で宣言してから再実験

3 確認

注入文がターンごとに変化することをログで確認した上で、なお動かない

届かなかったのではない。届いたのに、効かなかった

行動を1行書けば、動く

「合わせてしまうことがよくある」等、感情ではなく行動の傾向を書いた対照条件では

多数派に同調した率



最終回に裏切った率



感情の記述だけが、行動に翻訳されない

人間は、2つのモデルのあいだにいる

ハーネスも課題も同一のまま、中のAIモデルだけを替えると、挙動が反対側へ振れる



乖離はプロンプトの外、モデルの中に住む(規模と訓練は未分離の仮説)

人間らしさの二層分解

社会的な質感はコンテキストで作れる。非合理的な意思決定は、モデルの訓練の中に住む

- **作れた層** — 個性・本音と建前・裏切りのドラマ・30日の暮らし(状況の帰結として観測)
- **作れない層** — つられる・損切りできない等の非合理。感情をいくら書いても動かない
- **検証** — 4条件比較・予測の事前宣言・独立AI査読2系統。主張の撤回も経緯ごと公開
- **この地図の先** — 質感はハーネスで、非合理は訓練介入で。「人間の分布を持つ人工集団」へ

境界線を引いた者には、その先へ踏み出す権利がある