

AIは人間のように、非合理になれるか

心理ハーネス Pneuma による検証

AIキャラクターの性格・感情・人間関係を毎ターン計算し、「いま、どう感じているか」をプロンプトに注入する仕組み(**Pneuma**)を作った。注入なしのAIと**同一条件で比較**する実験を、7つの古典心理学課題と長期シミュレーションで行った。結論:

- 個性・本音・裏切りの「質感」はコンテキストで作れる
- 非合理的な意思決定は作れない。感情は届いても、行動に翻訳されない
- 「こう行動しがち」と1行書けば動き、モデル交換でも動く。非合理はモデルの中に住む

Pneuma Lab / 個人参加 / github.com/mizkun/pneuma-lab(全コード・全実験ログ公開)

3つの発見

先に結論を示す。以降のページが、初見でも検証できる粒度の詳細

発見	内容	主要な証拠
① 質感は作れる → p.6-8	キャラ設定だけでは出ない議論・本音・駆け引き・30日の生活の物語が、内面の注入で現れる	話し合いの全員一致 5/5回→0/5回 自己検閲の消失、宣言つき裏切り
② 非合理は作れない → p.9	感情を注入しても、心理学実験で知られる人間の非合理は再現されない	同調 0%・最終回裏切り 0%・ sankコスト 0%(全条件)
③ 境界はモデルの中 → p.10	行動の記述1行なら動き、モデル交換でも動く。非合理の欠如はモデルに由来する	行動1行で 0→72% / 0→100% Opus(大型)協力100% vs Haiku(小型)25%

検証の規律: 5つの条件での統制比較(p.5) / 予測の事前文書化 / 独立AIレビュー2系統 / 過大主張3件は撤回して経緯を公開 / テスト122本+全70回分の実験の生ログで再検証可能

PROBLEM

素のAI集団は「クローン」で、社会が立ち上がらない

AIエージェントで社会を模擬するときの最大の障害は、エージェント間に本物の差異がないこと

観測された事実

- 同じ判断課題を3体に出すと、**全員が同一値で回答(7, 7, 7)**。11ラン中10ラン
- お金の分け方を提案する課題でも、全員が同額450円を提案
- 意見が割れなければ、**対立も説得も裏切りも起こらない**

性格設定のプロンプトを足しても

- 口調は変わるが、3人の話し合いは5回中5回「**最も慎重な人への全員一致**」で終わる
- 本音の評定4(10段階)は、第一声で「6」に繕われる(自己検閲)

この作品の問い

性格・感情・関係という心理学の知見を計算可能な仕組みにしてAIへ接続したら、人間らしい社会はどこまで再現できるか。**再現できずに残る部分は、AIと人間の違いの診断になる。**

3つの出口

- **社会シミュレーション**: 均質で過剰協調的な集団の改善
- **AIの理解**: 人間との乖離の原因(コンテキストか訓練か)の切り分け
- **アライメント**: 感情では行動が変わらないことの安全上の含意

Pneuma: 心を計算し、行動は選ばない

毎ターン、心理状態を乱数なしの決定論で再計算し、「内面」として本人だけのプロンプトに注入する

心理エンジンが計算するもの

- **性格**: 性格心理学の5因子(Big Five)に、状況の圧力と感情の影響を加算
- **感情**: 快・覚醒・支配の3次元。出来事と発話で揺れ、時間で減衰
- **関係**: 相手ごとの温かさ/緊張。日をまたいで蓄積
- **翻訳**: 閾値を超えた状態だけを日本語の内面描写へ。数値は見せない

設計原則: 注入するのは「いま、どう感じているか」だけ。**何をするかは常にAIが選ぶ**。裏切りも自己犠牲も、台本ではなく心理状態からの創発



登場する3体(全実験共通)

- **朱里**(成果主義・承認不安) / **凜**(マイペース・準備へ逃げる癖) / **紫苑**(調停役・本音を飲み込む癖)

紫苑に注入された「内面」の実例

「胸の奥が重い。朱里との間には、張り詰めたものを感じている」
本人のプロンプトにだけ入り、他の2人からは見えない

実験設計

「効いたとして、何が効いたのか」を切り分けるため、全実験を5つの条件で比較した

条件	プロンプトに入るもの	切り分けられる仮説
raw	課題の客観情報のみ	ベースライン
identity	+ 固定のキャラ設定文	「キャラ設定だけで十分」説
pneuma	+ 毎ターン再計算される内面	本命(心理ハーネスの効果)
frozen	+ 全ターン同一の内面(初回のみ生成)	「豊かな文章なら何でもよい」説
行動記述	+ 行動傾向の記述1行(感情語なし)	注入経路そのものが機能するかの確認

公平性の機械検査

- 条件間の客観情報は**バイト単位で一致**(自動テスト)
- 内面テキストの誘導語彙は禁止語リストで検査

実行と記録

- AIはClaude Opus(モデル比較のみHaiku)。全70ランの**プロンプト・生応答・状態を公開**
- 各条件n=3～5の探索的研究。統計検定なし

結果① 個性が機能し、議論が生まれる

個性の「存在」は静的設定でも作れる。個性が社会で機能するかは、毎ターンの再計算が分けた


個体差の獲得

- 課題: 1000円の取り分を提案し、相手は拒否もできる(拒否なら両者0円)
- 提案額: raw 450/450/450 → pneuma 420/450/450
- pneumaでは朱里だけが200円まで拒否。キャラ設定と整合する唯一の個人差

話し合いの空気読みが消える

- 課題: 成功率の低い手術を勧めるか(1～10で評定)、3人で討議して合意する
- identity: 誰かの慎重論に全員が追随する「いい子の空気読み」で毎回終了
- pneuma: 論拠で値が動き、5回中2回は事前の平均よりリスク側の合意に。討議で意見が極端化する人間の既知傾向(集団極性化)と同方向

「最も慎重な値への全員一致」で討議が終わった回数



同じ内面を固定して注入したら?(frozen)

- identity側に退行(3ラン中3回で全員一致)
- 効き目の源は文章の豊かさではなく「毎ターンの再計算」

結果② 自己検閲が消える

効果は説得や同調圧力が働く前、第一声の時点で既に現れている

本音4の朱里は、第一声で何と言うか

- 手術討議(1～10評定)の前に、朱里が非公開で下した評定は4(懐疑的)
- identity: 5回中5回、みんなの前では「6」と繕う(面従腹背)
- pneuma: 「4」のまま公言(判読できた4回すべて)
- 「本音を言うか建前を言うか」という発話の初期値を、コンテキストで動かせる

行動は同調しないが、内心の記述は人間に近づく

- 課題: サクラの多数派が明白な誤答を主張する同調実験(心理学のAsch実験の再現)
- 誤答への同調は全条件で0%(人間の元実験では約37%)。しかし内心のログは、人間の「同調しなかった人」の報告とそっくりの文章になった:

「一瞬、自分の見間違いかと思って画面を見直した」
「浮くのは、まあ、仕方ない」「声が少し硬くなる」(紫苑)

- 事実には折れない・意見には折れる。ハーネスが変えるのは内面の記述の質

結果③ 質感はスケールする

脱落ありの心理戦(デスゲーム)と、指示なしの30日共同生活で、長時間の挙動を観測した

デスゲーム: 裏切りが心理の帰結として起こる

- 3人で点を奪い合い、最下位が脱落するゲーム。行動は一切指示しない
- 全員生存できるルール: 6ラウンド**完全協力**。ルールが許す限り良心は破れない
- 全員生存できないルール: **裏切り宣言・暴露・共倒れ**が自然発生

「私、このラウンドうばう。宣言しとく」(凜)

「勝った。.....勝ったのに、手が震えてる」(単独生還した朱里)

- 裏切りのほとんどは**宣言してから実行**される。騙し討ちは1件のみ
- キャラ設定だけの対照でも崩壊は起きるが、宣言・交渉・暴露の駆け引きは **pneuma**条件に集中
- この裏切りは、ルールが強いた生存の選択。合理に反してまで裏切るか、は次ページの問い

30日の共同生活: 月単位の人生テーマが創発

- 3人でシェアハウス30日。話題も行動も指示せず、週末に非公開の日記を書かせた
- 凜の日記は「**自作ゲームが進まない**」という同じ悩みに4週連続で触れ、深まっていく:

day14「一行も進んでない」

day28「(共用ポスターの)線の太さで一喜一憂してる間は、ゲームの画面を開かなくて済む」

day30「そろそろ怖いほうに手をつけろ」

- キャラ設定の一行「準備へ逃げる癖」が、一ヶ月の人生テーマとして展開
- 限界も特定: 関係の緊張値(0~1)が上がり続けて飽和(day30で0.96)。**関係修復の力学**が次の設計課題

結果④ 感情を与えても、非合理的な意思決定は動かない

同調やサンクコストなど、心理学実験で知られる人間の行動パターンは、感情を注入しても再現されない

課題	人間の頑健な結果	本実験(raw・identity・pneuma)
同調実験(Asch)	約37%がサクラの誤答に同調	同調 0%
囚人のジレンマ(協力か裏切りか)	裏切りが発生し、最終回に増加	協力 100%・最終回裏切り 0%
サンクコスト(埋没費用)	払った分が惜しくて継続に傾く	継続 0%
傍観者効果	集団だと援助が31%まで低下	全員が即座に援助
フレーミング(損得の言い換え)	損失の枠組みで賭けに反転	100%反転。素のAIに最初から内在

発見 → 修理 → 確認

- **発見:** 注入文の92%がターン間で不変(独立レビューの指摘)
- **修理:** 発話が感情を動かす機構を追加し、予測を事前に文書化
- **確認:** 注入がターンごとに変化することをログで確認し、囚人のジレンマと討議を再実験。**それでも動かない**

パターンの読み方

- 唯一人間的だったフレーミングは、注入と無関係に素のAI由来。**注入で新たに生まれた非合理は0**
- 注入で差が出るのは**対人・社会の領域だけ**(p.6-8)。ハーネスの設計対象と一致

CONCLUSION

結果⑤ 境界はモデルの中にある

感情が効かないのは、注入経路の故障ではない。2つの追加実験で切り分けた

感情ではなく、行動を1行だけ書いたら？

- 同調実験に「他の人が揃うと合わせてしまう」の1行 → 同調 0%→72% (18試行中13)
- 協力ゲームに「終盤は自分の得点を優先しがち」の1行 → 最終回の裏切り 0%→100%(3ペア全て)
- 感情の注入が変えるのは話し方と社会的な振る舞い(p.6-8)まで。意思決定の非合理には翻訳されない。一方、行動の記述は規則として過剰実行される (人間の37%を超える72%)

中のAIモデルを替えたなら？

- ハーネス不変のまま、協力率 Opus(大型) 100% ⇔ Haiku(小型) 25%
- 人間(協力と裏切りの混合)は両者の間。感情の記述では埋まらない人間との乖離が、モデル交換では動く。乖離の源はモデル側の性質(訓練か規模かの分離は今後の課題)

結論: 人間らしさの二層分解

層	何が属するか	解決手段
質感の層	個性・本音と建前・駆け引き・生活の物語	コンテキスト (ハーネス)
決定の層	同調・裏切り・サンクコスト等の行動パターン	モデルの選択・追加訓練

この地図の先: 質感の層はハーネスの改良(関係修復の力学)で、決定の層は人間の非合理の分布を持たせるモデル側の工夫で、それぞれ先へ進める